

Bayes

I Giới thiệu

Bayes là một phương pháp dựa trên **Định lý Bayes** trong xác suất thống kê, dùng để đánh giá xác suất của một giả thuyết dựa trên dữ liệu quan sát được. Ý tưởng chính: **cập nhật xác suất của một giả thuyết khi có thông tin mới**. Bayes giúp kết hợp kiến thức trước đó (prior) với bằng chứng mới để đưa ra quyết định tốt hơn.

1. Giới thiệu về Naive Bayes

Naive Bayes là một ứng dụng phổ biến của Bayes cho bài toán phân loại. Thuật toán giả định rằng các đặc trưng (features) là **độc lập có điều kiện** khi biết nhãn (class).

Điểm nổi bật:

- Rất trực quan và dễ hiểu.
- Hiệu quả với tập dữ liệu lớn.
- Phù hợp với nhiều loại dữ liệu: dữ liệu số, dữ liệu rời rạc, dữ liệu nhị phân.
- Nền tảng cho nhiều biến thể như Gaussian Naive Bayes, Multinomial Naive Bayes, Bernoulli Naive Bayes.

Naive Bayes thường được sử dụng trong các ứng dụng như:

- Phân loại văn bản, ví dụ: nhận dạng spam/ham trong email.
- Dự đoán bệnh dựa trên triệu chứng.
- Hệ thống gợi ý dựa trên đặc điểm người dùng.

2. Phân loại các loại Naive Bayes

Tùy vào loại dữ liệu và giả định phân phối, Naive Bayes được chia thành các loại phổ biến:

- **Gaussian Naive Bayes:** Dùng cho các feature liên tục.

- **Multinomial Naive Bayes:** Dùng cho dữ liệu rời rạc hoặc đếm (count data).
- **Bernoulli Naive Bayes:** Dùng cho dữ liệu nhị phân (0/1).

II. Toán học đằng sau

1. Naive Bayes chung

Giả sử tập dữ liệu có các class $C_1, C_2, \dots, C_k$ và mẫu mới $X = (x_1, x_2, \dots, x_n)$.
Công thức chung:

$$P(C_j | X) = \frac{P(C_j) \cdot P(X | C_j)}{P(X)}$$

Với giả định các feature độc lập có điều kiện:

$$P(X | C_j) = P(x_1 | C_j) \cdot P(x_2 | C_j) \cdot \dots \cdot P(x_n | C_j)$$

Class dự đoán là class có xác suất posterior cao nhất:

$$\hat{C} = \arg \max_{C_j} P(C_j) \prod_{i=1}^n P(x_i | C_j)$$

Giải thích:

- $P(C_j)$: tỷ lệ class trong dữ liệu huấn luyện
- $P(x_i | C_j)$: xác suất feature i xuất hiện khi biết class
- Posterior: xác suất class khi biết mẫu mới

2. Gaussian Naive Bayes (cho feature liên tục)

Giả định feature x_i tuân theo phân phối Gaussian (Normal) trong mỗi class.
Xác suất feature:

$$P(x_i | C_j) = \frac{1}{\sqrt{2\pi\sigma_{C_j}^2}} \exp\left(-\frac{(x_i - \mu_{C_j})^2}{2\sigma_{C_j}^2}\right)$$

- μ_{C_j} : trung bình của feature i trong class C_j
- $\sigma_{C_j}^2$: phương sai của feature i trong class C_j

Giải thích:

Likelihood được tính bằng mật độ xác suất chuẩn. Feature càng gần trung bình, xác suất càng cao.

3. Multinomial Naive Bayes (cho dữ liệu đếm)

Dữ liệu feature là số lần xuất hiện (count).

Xác suất feature i trong class j:

$$P(x_i | C_j) = \frac{N_{i|C_j} + \alpha}{N_{C_j} + \alpha n}$$

- $N_{i|C_j}$: số lần feature i xuất hiện trong class C_j
- N_{C_j} : tổng số từ trong class C_j
- n : số lượng feature khác nhau
- α : hệ số smoothing (để tránh 0)

Giải thích:

Tính xác suất dựa trên tần suất xuất hiện. Phù hợp cho dữ liệu văn bản, email spam, tần suất từ.

4. Bernoulli Naive Bayes (cho dữ liệu nhị phân)

Dữ liệu feature là nhị phân (0/1).

Xác suất feature i trong class j:

$$P(x_i = 1 | C_j) = \frac{N_{i|C_j} + \alpha}{N_{C_j} + 2\alpha}, \quad P(x_i = 0 | C_j) = 1 - P(x_i = 1 | C_j)$$

- $N_{i|C_j}$: số mẫu có feature i = 1 trong class C_j
- N_{C_j} : tổng số mẫu trong class C_j
- α : smoothing

Giải thích:

Tính xác suất dựa trên hiện diện/không hiện diện của feature. Thích hợp với feature dạng yes/no hoặc có/không.

III. Ưu nhược điểm của Naive Bayes và 3 biến thể

1. Naive Bayes chung

Ưu điểm:

- Dễ hiểu, dễ triển khai.
- Nhanh và hiệu quả với tập dữ liệu lớn.

- Hoạt động tốt với dữ liệu rời rạc và nhị phân.
- Ít bị ảnh hưởng bởi số lượng feature lớn.

Nhược điểm:

- Giả định các feature độc lập có điều kiện, điều này hiếm khi đúng trong thực tế.
- Kém chính xác nếu feature có tương quan mạnh.
- Xác suất posterior có thể sai lệch nếu dữ liệu ít hoặc mất cân bằng.

2. Gaussian Naive Bayes

Ưu điểm:

- Thích hợp cho feature liên tục.
- Nhanh, đơn giản, không cần chuẩn hóa dữ liệu phức tạp.
- Có thể áp dụng cho nhiều bài toán phân loại số liệu thực.

Nhược điểm:

- Giả định feature tuân theo phân phối Gaussian, nếu dữ liệu lệch chuẩn sẽ ảnh hưởng đến kết quả.
- Nhạy cảm với outlier.

3. Multinomial Naive Bayes

Ưu điểm:

- Phù hợp với dữ liệu đếm, đặc biệt là văn bản và tài liệu.
- Xử lý tốt feature tần suất xuất hiện.
- Hiệu quả với tập dữ liệu lớn.

Nhược điểm:

- Không phù hợp cho feature liên tục.
- Giả định các feature rời rạc độc lập, nếu từ xuất hiện có liên quan lẫn nhau sẽ làm giảm độ chính xác.

4. Bernoulli Naive Bayes

Ưu điểm:

- Phù hợp với dữ liệu nhị phân (0/1).
- Dễ triển khai với feature dạng hiện diện/không hiện diện.
- Hiệu quả cho các bài toán phân loại văn bản dựa trên việc xuất hiện từ.

Nhược điểm:

- Không dùng được cho dữ liệu đếm hoặc dữ liệu liên tục.
- Giả định độc lập các feature, nếu nhiều feature có liên quan sẽ làm giảm độ chính xác.