

Decision Tree

I. Giới thiệu về Decision Tree

Decision Tree (Cây quyết định) là một trong những thuật toán trực quan và dễ hiểu nhất trong Machine Learning. Ý tưởng của nó mô phỏng cách con người đưa ra quyết định: bắt đầu từ gốc, đặt ra một câu hỏi, phân nhánh theo câu trả lời và cuối cùng đi đến lá – nơi chứa dự đoán.

Ở mỗi nút, mô hình sẽ chọn ra đặc trưng tốt nhất để chia tách dữ liệu sao cho các nhóm sau khi tách trở nên “thuần” hơn.

Decision Tree có thể hoạt động với cả:

- Classification (phân loại)
- Regression (hồi quy)

Đặc biệt, Decision Tree còn là nền tảng của nhiều thuật toán mạnh hơn như Random Forest, Gradient Boosting, XGBoost, CatBoost, LightGBM, ...

Chính nhờ tính trực quan và khả năng mô tả quan hệ phi tuyến, Decision Tree trở thành một trong những thuật toán được dùng nhiều nhất trong thực tế.

II. Toán học đằng sau

Quy trình toán học của Decision Tree xoay quanh việc tìm cách chia tách dữ liệu tối ưu tại mỗi nút. Thuật toán sẽ duyệt qua tất cả các đặc trưng và lựa chọn ngưỡng tách sao cho “độ hỗn loạn” của hai nhóm con sau khi chia giảm xuống nhiều nhất.

1. Với bài toán Classification

Các chỉ số đo độ “hỗn loạn” (impurity) phổ biến:

Gini Impurity

$$\text{Gini} = 1 - \sum_{i=1}^C p_i^2$$

Entropy (ID3)

$$\text{Entropy} = - \sum_{i=1}^C p_i \log_2(p_i)$$

Trong đó:

- C là số lớp (nhãn) trong dữ liệu.
- p_i là tỷ lệ mẫu thuộc lớp i trong nhánh đang xét.
- Ví dụ, nếu nhánh có 10 mẫu, trong đó 7 mẫu nhãn A, 3 mẫu nhãn B, thì $p_A = 7/10 = 0.7$, $p_B = 3/10 = 0.3$.
- Chỉ số Gini hoặc Entropy càng nhỏ $\Rightarrow$ nhánh càng “thuần” (tức chứa nhiều mẫu cùng nhãn).

Mô hình sẽ chọn phép chia giảm impurity xuống nhiều nhất.

2. Với bài toán Regression

Độ lỗi được đo bằng:

MSE (Mean Squared Error)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

MAE

$$\text{MAE} = \frac{1}{n} \sum |y_i - \bar{y}|$$

Thuật toán chọn phép tách sao cho MSE hoặc MAE của hai nhóm con nhỏ nhất.

Ví dụ Decision Tree (Classification)

Giả sử ta có dữ liệu như sau:

Feature A	Feature B	Target
High	Yes	1
High	No	0
Low	Yes	0
Low	No	0
High	Yes	1

Bước 1: Tính Gini cho node gốc (Root Node)

- Target 1: 2 lần
- Target 0: 3 lần

$$\text{Gini}_{\text{root}} = 1 - (p_0^2 + p_1^2) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0.48$$

Bước 2: Xem xét tách theo Feature A

- Feature A = High $\rightarrow$ 3 mẫu: [1, 0, 1]

$$\text{Gini}_{\text{High}} = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0.444$$

- Feature A = Low $\rightarrow$ 2 mẫu: [0, 0]

$$\text{Gini}_{\text{Low}} = 1 - (0^2 + 1^2) = 0$$

Gini tách theo Feature A:

$$\text{Gini}_{\text{splitA}} = \frac{3}{5} \cdot 0.444 + \frac{2}{5} \cdot 0 = 0.2664$$

Bước 3: Xem xét tách theo Feature B

- Feature B = Yes $\rightarrow$ 3 mẫu: [1, 0, 0]

$$\text{Gini}_{\text{Yes}} = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0.444$$

- Feature B = No $\rightarrow$ 2 mẫu: [0, 1]


$$\text{Gini}_{\text{No}} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

Gini tách theo Feature B:

$$\text{Gini}_{\text{splitB}} = \frac{3}{5} \cdot 0.444 + \frac{2}{5} \cdot 0.5 = 0.466$$

Bước 4: Chọn feature tách

Gini giảm mạnh nhất khi tách theo Feature A ($0.266 < 0.466$). Vậy node gốc sẽ tách theo Feature A.



Decision Tree plot

I Ưu nhược điểm của Decision Tree

Ưu điểm

- **Trực quan, dễ hiểu:** Cây quyết định mô phỏng cách con người ra quyết định: từ gốc $\rightarrow$ nhánh $\rightarrow$ lá. Kết quả dự đoán có thể giải thích bằng câu hỏi/nút trên cây.
- **Không cần chuẩn hóa dữ liệu:** Không giống như SVM hay KNN, Decision Tree không yêu cầu chuẩn hóa hay scaling dữ liệu.
- **Xử lý cả dữ liệu số và dữ liệu danh mục:** Có thể dùng trực tiếp với biến liên tục (numerical) và biến rời rạc (categorical).
- **Khả năng nắm bắt quan hệ phi tuyến và tương tác biến:** Tự động phát hiện các mối quan hệ phức tạp giữa các feature mà không cần biến đổi dữ liệu.
- **Nhanh, hiệu quả với dữ liệu lớn:** Thuật toán tách nhánh từng bước giúp giảm số tính toán so với các thuật toán tính toàn bộ ma trận khoảng cách như KNN.
- **Nền tảng cho các mô hình mạnh hơn:** Là cơ sở của các ensemble methods như Random Forest, Gradient Boosting, XGBoost, LightGBM.

Nhược điểm

- **Dễ overfitting:** Cây sâu hoặc có nhiều nhánh sẽ khớp quá mức với dữ liệu huấn luyện. Cần áp dụng pruning để kiểm soát.
- **Nhạy cảm với dữ liệu nhiễu (noise):** Một vài mẫu bất thường có thể làm thay đổi hoàn toàn cấu trúc cây.
- **Thiếu ổn định:** Thay đổi nhẹ trong dữ liệu có thể dẫn đến cây hoàn toàn khác.
- **Cây lớn mất tính trực quan:** Khi cây quá sâu, khó để giải thích hoặc trực quan hóa toàn bộ cấu trúc.
- **Giới hạn với quyết định phức tạp:** Nếu ranh giới quyết định rất phức tạp hoặc mịn, một cây đơn lẻ khó đạt độ chính xác cao. Thường cần các mô hình ensemble để cải thiện.