

Hierarchical Clustering

I Giới thiệu về Hierarchical Clustering

Hierarchical Clustering (Phân cụm theo cấu trúc phân cấp) là một phương pháp **unsupervised learning** trong Machine Learning, được dùng để nhóm các đối tượng dựa trên sự **tương đồng (similarity)** giữa chúng.

Điểm đặc trưng của phương pháp tạo ra một **cây phân cấp (dendrogram)**, thể hiện mối quan hệ gần xa giữa các dữ liệu:

- **Agglomerative (Bottom-up)**: bắt đầu từ mỗi điểm là một cụm riêng lẻ, rồi dần dần gộp các cụm gần nhau lại đến khi còn 1 cụm duy nhất.
- **Divisive (Top-down)**: bắt đầu từ một cụm lớn chứa tất cả điểm, rồi tách dần thành các cụm nhỏ hơn.

Hierarchical Clustering không cần số lượng cụm k cố định từ đầu, khác với K-Means, nhưng bạn có thể “cắt” dendrogram ở mức phù hợp để chọn số cụm mong muốn.

II Toán học đằng sau

Cốt lõi của Hierarchical Clustering là **tính khoảng cách (distance)** giữa các điểm và giữa các cụm, từ đó quyết định cách gộp hoặc tách cụm.

1. Khoảng cách giữa các điểm

Đầu tiên, cần định nghĩa khoảng cách giữa hai điểm x và y trong không gian n -chiều:

- **Khoảng cách Euclidean (phổ biến nhất)**:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- **Khoảng cách Manhattan (city block)**:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Khoảng cách này đo mức độ khác biệt giữa hai điểm. Càng nhỏ thì hai điểm càng giống nhau.

2. Khoảng cách giữa các cụm (Linkage methods)

Khi đã có nhiều điểm nhóm thành các cụm, ta cần đo khoảng cách giữa các cụm. Một số phương pháp phổ biến:

- **Single linkage (khoảng cách nhỏ nhất):**

$$D(A, B) = \min_{x \in A, y \in B} d(x, y)$$

Khoảng cách giữa hai cụm là cặp điểm gần nhất.

- **Complete linkage (khoảng cách lớn nhất):**

$$D(A, B) = \max_{x \in A, y \in B} d(x, y)$$

Khoảng cách giữa hai cụm là cặp điểm xa nhất, giúp tạo cụm hình tròn đều hơn.

- **Average linkage (trung bình khoảng cách):**

$$D(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y)$$

Khoảng cách trung bình giữa tất cả các cặp điểm thuộc hai cụm.

- **Ward's method:** Chọn cụm để gộp sao cho tổng phương sai trong cụm (within-cluster variance) tăng ít nhất. Đây là phương pháp tối ưu hóa nội tại cấu trúc dữ liệu.


3. Quy trình toán học

1. Khởi tạo: mỗi điểm dữ liệu là một cụm.
2. Tính tất cả các khoảng cách giữa các cụm.
3. Tìm cặp cụm A, B gần nhau nhất theo phương pháp linkage.
4. Gộp A và B thành cụm mới.
5. Cập nhật khoảng cách giữa cụm mới và các cụm còn lại.
6. Lặp lại bước 3–5 cho đến khi đạt điều kiện dừng (ví dụ còn một cụm hoặc đạt số cụm mong muốn).


Kết quả cuối cùng được thể hiện dưới dạng **dendrogram**, từ đó có thể “cắt” cây ở mức độ phù hợp để xác định số lượng cụm.

III Ví dụ trên bộ dữ liệu Iris

1. Trước khi phân cụm




2. Dendrogram




Nhìn vào Dendrogram ta thấy nếu ngắt cụm ở 3 thì các cụm được phân rất hợp lý, nhưng nếu muốn xem thử các cụm khác, ta có thể chọn các cụm và dùng scatter plot để có cái nhìn trực quan hơn

3. Sau khi phân cụm



4. Thực tế



IV Ưu điểm & Nhược điểm

1. Ưu điểm

- **Không cần xác định số cụm từ đầu:** Bạn có thể quan sát dendrogram và chọn số cụm phù hợp, linh hoạt hơn K-Means.
- **Hiển thị cấu trúc phân cấp trực quan:** Dendrogram giúp thấy mối quan hệ gần xa giữa các điểm dữ liệu.
- **Thích hợp với dữ liệu phức tạp:** Có thể xử lý dữ liệu có hình dạng cụm không đồng nhất hoặc không tuyến tính.
- **Dễ giải thích và trực quan:** Cách gộp/tách cụm dễ hình dung, gần giống cách con người nhóm đối tượng.

2. Nhược điểm

- **Tốn bộ nhớ và thời gian:** Đặc biệt với dữ liệu lớn, Agglomerative Clustering có độ phức tạp $O(n^3)$ và tốn $O(n^2)$ bộ nhớ.

- **Không thể “sửa lại” sau khi gộp/tách:** Một khi đã gộp hoặc tách nhầm cụm, thuật toán không quay lại điều chỉnh.
- **Kết quả nhạy với khoảng cách và phương pháp linkage:** Chọn single, complete, average hay ward có thể dẫn đến cụm khác nhau.
- **Khó mở rộng với dữ liệu nhiều chiều hoặc lớn:** Khi số lượng điểm và chiều dữ liệu tăng, tính toán dendrogram sẽ chậm và khó trực quan hóa.