

K-Nearest Neighbors

I Giới thiệu

K-Nearest Neighbors (KNN) là một trong những thuật toán đơn giản và trực quan nhất trong học máy. Ý tưởng của KNN dựa trên giả định rằng những điểm dữ liệu gần nhau trong không gian đặc trưng sẽ có xu hướng giống nhau.

Khi gặp một dữ liệu mới $\mathbf{x}_{\text{mới}}$, KNN sẽ tìm k điểm láng giềng gần nhất trong tập huấn luyện và dùng thông tin của chúng để dự đoán nhãn (Classification) hoặc giá trị (Regression) cho $\mathbf{x}_{\text{mới}}$.

KNN là một thuật toán non-parametric (phi tham số). Nó không giả định trước hình dạng của dữ liệu và không có phương trình hay trọng số cố định.

- **Phân loại (Classification):** dự đoán nhãn dựa trên **đa số** của k láng giềng gần nhất.
- **Hồi quy (Regression):** dự đoán giá trị liên tục bằng cách lấy **trung bình** hoặc **trọng số** của các láng giềng gần nhất.

II Nguyên tắc hoạt động

II.1 Ý tưởng của mô hình

Mô hình KNN dựa trên khoảng cách. Ba bước chính để dự đoán cho một điểm mới $\mathbf{x}_{\text{mới}}$:

1. **Tính khoảng cách** giữa $\mathbf{x}_{\text{mới}}$ và tất cả điểm dữ liệu $\mathbf{x}_i$ trong tập huấn luyện.
2. **Chọn K điểm** có khoảng cách nhỏ nhất.
3. **Dự đoán dựa trên các láng giềng:**
 - Classification: nhãn theo đa số (*majority vote*).
 - Regression: giá trị trung bình của K láng giềng.

II.2 Các công thức khoảng cách thường dùng

Cho hai điểm dữ liệu $\mathbf{x} = (x_1, x_2, \dots, x_p)$ và $\mathbf{z} = (z_1, z_2, \dots, z_p)$ trong không gian p chiều:

1. **Euclidean Distance (L2 norm):**

$$d_{\text{Euc}}(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{i=1}^p (x_i - z_i)^2}$$

2. **Manhattan Distance (L1 norm):**

$$d_{\text{Man}}(\mathbf{x}, \mathbf{z}) = \sum_{i=1}^p |x_i - z_i|$$

3. **Minkowski Distance (Tổng quát hóa L1 và L2):**

$$d_{\text{Min}}(\mathbf{x}, \mathbf{z}) = \left(\sum_{i=1}^p |x_i - z_i|^q \right)^{1/q}$$

- $q = 1 \rightarrow$ Manhattan Distance
- $q = 2 \rightarrow$ Euclidean Distance

II.3 Công thức dự đoán tổng quát

Cho tập K láng giềng $\mathcal{N}_k(\mathbf{x}_{\text{mới}})$ với nhãn/giá trị y_i tương ứng.

1. **Classification (Phân loại):** Dự đoán nhãn $\hat{y}$ là nhãn xuất hiện nhiều nhất trong K láng giềng (phương pháp Bỏ phiếu Đa số).

$$\hat{y} = \text{mode}(y_{i_1}, y_{i_2}, \dots, y_{i_K})$$

Trong đó: $y_{i_1}, y_{i_2}, \dots, y_{i_K}$ là các nhãn của K láng giềng gần nhất. Hàm mode trả về giá trị xuất hiện thường xuyên nhất.

2. **Regression (Hồi quy):** Dự đoán giá trị $\hat{y}$ là giá trị trung bình của K láng giềng.

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K y_{i_k}$$

Trong đó: y_{i_k} là giá trị của láng giềng thứ k , và $\sum_{k=1}^K y_{i_k}$ là tổng của K giá trị này. Giá trị dự đoán là trung bình cộng của chúng.

II.4 Ví dụ KNN Regression (Euclidean)

Dataset 10 điểm, 2 features:

ID	$\mathbf{x}_1$	$\mathbf{x}_2$	y
1	1	1	4
2	2	1	5
3	3	1	7
4	4	2	8
5	5	2	9
6	6	3	12
7	7	3	13
8	8	3	14
9	9	4	15
10	10	4	17

Điểm cần dự đoán: $\mathbf{x}_{\text{mới}} = (4, 3)$. Chọn $K = 3$.

Bước 1 – Tính khoảng cách Euclidean Cho điểm $\mathbf{x}_{\text{mới}} = (4, 3)$ và một điểm $\mathbf{x}_i = (x_{i1}, x_{i2})$, khoảng cách là:

$$d(\mathbf{x}_{\text{mới}}, \mathbf{x}_i) = \sqrt{(x_{i1} - 4)^2 + (x_{i2} - 3)^2}$$


Bảng khoảng cách (đã tính):

ID	(x_1, x_2)	d	y
4	(4, 2)	1.000	8
5	(5, 2)	1.414	9
6	(6, 3)	2.000	12
3	(3, 1)	2.236	7
2	(2, 1)	2.828	5
...	...	...	...

$K = 3$ láng giềng gần nhất là ID 4, 5, 6 với giá trị y tương ứng là 8, 9, 12.

Bước 2 – Dự đoán Áp dụng công thức KNN Regression (trung bình):

$$\hat{y} = \frac{1}{3} \sum_{i \in \{4, 5, 6\}} y_i = \frac{8 + 9 + 12}{3} = \frac{29}{3} \approx 9.67$$



Biểu đồ 3D cho mô hình KNN

III Ưu điểm & Nhược điểm

III.1 Ưu điểm

- **Dễ hiểu, dễ triển khai:** Mô hình trực quan, không cần hàm mất mát hay tối ưu tham số.
- **Không cần quá trình huấn luyện phức tạp (Lazy Learning):** Mọi xử lý được thực hiện ở lúc dự đoán, giúp xây dựng mô hình nhanh.
- **Ít giả định về dữ liệu (Non-parametric):** Phù hợp với dữ liệu có cấu trúc phức tạp hoặc phi tuyến tính.
- **Hoạt động tốt với dataset nhỏ:** Hiệu quả và dễ giải thích khi số lượng mẫu ít.

III.2 Nhược điểm

- **Chậm khi dữ liệu lớn:** Để dự đoán một điểm mới, KNN phải tính khoảng cách với tất cả N điểm dữ liệu.
 - Độ phức tạp tính toán (ở bước dự đoán): $\mathcal{O}(N \cdot p)$, với p là số chiều.
 Nếu N lớn (hàng triệu), mô hình trở nên rất chậm.

- **Nhạy với outlier (điểm bất thường):** Outlier có thể nằm gần điểm cần dự đoán và làm sai lệch kết quả (đặc biệt khi K nhỏ).
- **Bắt buộc phải chuẩn hóa dữ liệu (Scaling):** Vì mô hình dựa hoàn toàn vào khoảng cách, các features có thang đo lớn sẽ chi phối toàn bộ kết quả.
- **Việc chọn K ảnh hưởng mạnh tới hiệu suất:**
 - K nhỏ $\rightarrow$ dễ *overfit*, nhạy với nhiễu.
 - K lớn $\rightarrow$ dễ *underfit*, mờ biên quyết định.