

Linear Regression dưới góc nhìn toán học

I Giới thiệu về Hồi quy Tuyến tính

I.1 Linear regression là gì?

Linear regression (hồi quy tuyến tính) là một mô hình **Statistical** (thống kê) và **Machine Learning** (học máy) dùng để dự báo **biến mục tiêu** y dựa vào các **biến đầu vào** $x_1, x_2, \dots, x_n$.

Mô hình giả sử biến đầu vào x và biến mục tiêu y là **tuyến tính**, tức là y có thể biểu diễn như một tổ hợp tuyến tính của các biến x

$$y = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Trong đó:

w_0 là **hệ số chặn** (intercept)

$[w_1, w_2, \dots, w_n]$ là các **trọng số** (weights) tương ứng với từng biến đầu vào

I.2 Ứng dụng

Kinh tế & tài chính: Dự đoán giá cổ phiếu, doanh thu, lợi nhuận dựa trên các yếu tố kinh tế và chỉ số thị trường

Y tế: Dự đoán mức cholesterol, huyết áp, cân nặng, ... dựa trên các chỉ số sinh lý hoặc lối sống.

Khoa học & kĩ thuật: Dự đoán nhiệt độ, áp suất, lượng mưa, tốc độ phản ứng hóa học, ... dựa trên các điều kiện đầu vào.

Khoa học dữ liệu & học máy: Dự đoán **giá trị liên tục** (regression problems) trong các bộ dữ liệu Kaggle, bài toán khoa học dữ liệu thực tế. Là mô hình cơ bản để hiểu cách các thuật toán học từ dữ liệu và đo lường lỗi.

I.3 Khái niệm Least Squared

Least Squares (tối thiểu hóa bình phương sai số) là phương pháp dùng để tìm các **hệ số** w của Linear Regression sao cho **sai số dự đoán** là **nhỏ nhất**.

Sai số dự đoán (residual) với mỗi điểm dữ liệu:

$$r_i = y_i - \hat{y}_i = y_i - (w_0 + w_1 x_{i1} + \dots + w_n x_{in})$$

Trong đó:

y_i là các **biến mục tiêu** (giá trị thực tế)

$\hat{y}_i$ là các **giá trị được dự đoán** (giá trị ước lượng bởi mô hình)

r_i là **sai số dự đoán** (residual)

Ý tưởng: **tổng bình phương các residual nhỏ nhất**:

$$\min J(\mathbf{w}) = \sum_{i=1}^n r_i^2 = \sum_{i=1}^n (y_i - (w_0 + w_1 x_{i1} + \dots + w_n x_{in}))^2$$

Bình phương loại bỏ dấu âm, đảm bảo mỗi residual đóng góp dương vào tổng lỗi. Cách này còn giúp hạn chế cân nhắc quá mức các residual nhỏ và **nhấn mạnh các residual lớn**, rất tiện cho tính toán đạo hàm.

Một cách Trực quan:

- Mỗi **residual** r_i là **khoảng cách theo trục y** từ điểm dữ liệu đến đường thẳng (hoặc mặt phẳng trong đa biến).
- **Least Squares** tìm đường thẳng/mặt phẳng sao cho **tổng bình phương các khoảng cách này nhỏ nhất**.

II Simple Linear Regression

II.1 Mô hình

Với một biến đầu vào x và biến mục tiêu y , mô hình **hồi quy tuyến tính đơn** là:

$$y \approx \hat{y} = w_0 + w_1 x$$

II.2 Loss function (Least Squares)

Sai số residual với mỗi điểm:

$$r_i = y_i - \hat{y}_i = y_i - (w_0 + w_1 x_i)$$

Mục tiêu: Tìm w_0 và w_1 sao cho J nhỏ nhất.

Các bước tìm w_0 và w_1

a. Tìm nghiệm bằng đạo hàm

Ta lấy **đạo hàm riêng** của J theo w_0 và w_1 , và đặt chúng bằng 0:

$$\frac{\partial J}{\partial w_0} = -2 \sum_{i=1}^n (y_i - w_0 - w_1 x_i) = 0$$

$$\frac{\partial J}{\partial w_1} = -2 \sum_{i=1}^n x_i (y_i - w_0 - w_1 x_i) = 0$$

b. Giải hệ phương trình

Giải 2 phương trình trên ta được nghiệm của hệ (trong đó $\bar{x}$ và $\bar{y}$ là **trung bình mẫu** của x và y):

$$w_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$w_0 = \bar{y} - w_1 \bar{x}$$

Ví dụ Minh Họa (Dữ liệu Gần Tuyến Tính)

Chúng ta có bộ dữ liệu mẫu với $n = 5$ điểm:

X	1	2	3	4	5
Y	48	63	69	83	88

1. Tính toán Trung bình

Trung bình mẫu:

$$\bar{x} = 3, \quad \bar{y} = \frac{48 + 63 + 69 + 83 + 88}{5} = 70.2$$

2. Tính toán hệ số w_1

Ta dùng công thức:

$$w_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Tổng:

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 44.4 + 7.2 + 0 + 12.8 + 35.6 = 100$$

Mẫu số:

$$\sum (x_i - \bar{x})^2 = 4 + 1 + 0 + 1 + 4 = 10$$

Do đó:

$$w_1 = \frac{100}{10} = 10$$

3. Tính toán hệ số w_0


$$w_0 = \bar{y} - w_1 \bar{x} = 70.2 - 10 \cdot 3 = 40.2$$

4. Kết quả Mô hình

Phương trình hồi quy tuyến tính đơn là:

$$\hat{y} = 40.2 + 10x$$

5. Minh họa mô hình và dự đoán giá trị



Biểu đồ phân tán dữ liệu $X - Y$ và **đường hồi quy tuyến tính** $\hat{y} = 40.2 + 10x$.

Với phương trình hồi quy $\hat{y} = 40.2 + 10x$, ta có thể **dự đoán các giá trị**:

- Nếu $X = 6$, Mức lương dự đoán: $\hat{y} = 40.2 + 10(6) = 100.2$
- Nếu $X = 0$, Mức lương dự đoán: $\hat{y} = 40.2 + 10(0) = 40.2$

III Multiple Linear Regression

III.1 Mô hình

Với m **biến đầu vào** $x_1, x_2, \dots, x_m$ và biến mục tiêu y , mô hình **hồi quy tuyến tính đa biến** là:

$$y \approx \hat{y} = w_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m$$

Viết gọn bằng **vector/matrix**:

$$y \approx \hat{y} = Xw$$

Trong đó:

$y \in R^{n \times 1}$ là **vector target** (biến mục tiêu).

$X \in R^{n \times (m+1)}$ là **ma trận feature** (cột đầu tiên toàn 1 cho intercept).

$w \in R^{(m+1) \times 1}$ là **vector trọng số**: $[w_0, w_1, \dots, w_m]^T$.

III.2 Loss function (Least Squares)

Residual vector:

$$r = y - \hat{y} = y - Xw$$

Tổng bình phương residual (Loss function):

$$J(w) = r^T r = (y - Xw)^T (y - Xw)$$

Mục tiêu: **Tìm vector** w làm cho w nhỏ nhất.

Tìm nghiệm bằng đạo hàm


Lấy **đạo hàm** của J theo w :

$$\frac{\partial J}{\partial w} = -2X^T(y - Xw) = 0$$

Giải phương trình (đặt đạo hàm bằng vector 0):

$$w = (X^T X)^{-1} X^T y$$

Minh họa mô hình



Mô hình **Multiple Linear Regression** trên mặt phẳng 3D,


IV Ưu điểm và Nhược điểm

IV.1 Ưu điểm

- **Đơn giản và dễ hiểu** **Linear Regression** là một trong những mô hình dễ hiểu nhất. Quan hệ giữa biến đầu vào và biến đầu ra được biểu diễn qua **phương trình tuyến tính**, giúp việc **giải thích** rất trực quan.
- **Tính diễn giải cao (Interpretability)** Các hệ số w_i cho biết mức độ **ảnh hưởng** của từng biến x_i lên y . Điều này cực kỳ quan trọng trong các lĩnh vực yêu cầu **giải thích mô hình** như kinh tế, tài chính, y tế.
- **Tốc độ huấn luyện nhanh** Nghiệm đóng $w = (X^T X)^{-1} X^T y$ giúp mô hình **training** gần như tức thì với dữ liệu nhỏ hoặc trung bình.
- **Hiệu quả với dữ liệu tuyến tính** Nếu dữ liệu có quan hệ **tuyến tính** hoặc gần tuyến tính, **Linear Regression** hoạt động rất tốt và cho kết quả chính xác.

IV.2 Nhược điểm

- **Giả định tuyến tính** Mô hình chỉ học được **quan hệ tuyến tính**. Nếu dữ liệu **phi tuyến** mà không xử lý feature, mô hình sẽ **dự đoán rất kém**.
- **Nhạy cảm với Outliers (giá trị ngoại lai)** Vì dùng **Least Squares** (bình phương sai số), nên chỉ một vài điểm **outlier** có thể kéo đường hồi quy lệch rất mạnh.



Mô hình ảnh hưởng rất nhiều bởi outliers

- **Không tự động nắm bắt tương tác giữa các biến** Nếu mô hình cần dạng:

$$y = w_1x_1 + w_2x_2 + w_{12}x_1x_2$$

thì ta phải **tự thêm feature** x_1x_2 . Mô hình **không tự học được tương tác**.

- **Kém hiệu quả với dữ liệu lớn** nếu dùng **Closed-form** Nghiệm đóng cần tính **nghịch đảo** của $X^T X$, độ phức tạp $O(m^3)$