

Logistic regression dưới góc nhìn toán học

I Giới thiệu

I.1 Định nghĩa

Logistic Regression là một mô hình học máy thuộc nhóm *supervised learning*, được sử dụng chủ yếu trong phân loại nhị phân (binary classification), khi đầu ra chỉ có hai khả năng, ví dụ:

- Có mắc bệnh hay không (Yes/No)
- Có mua sản phẩm hay không (1/0)
- Email có phải spam hay không

Không giống Linear Regression dự đoán giá trị liên tục, Logistic Regression dự đoán **xác suất** một mẫu thuộc lớp 1 thông qua hàm sigmoid.

I.2 Lịch sử và bối cảnh

Logistic Regression ra đời từ thống kê cổ điển, trước khi được áp dụng rộng rãi trong học máy. Do mô hình đơn giản, dễ giải thích và hoạt động tốt trên dữ liệu vừa và nhỏ, nó được dùng trong y sinh học, tài chính, kinh tế lượng, tiếp thị, v.v.

II Logistic Regression

II.1 Ý tưởng chính

Logistic Regression dựa trên **kết hợp tuyến tính (linear combination)** của các biến đầu vào:

$$z = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n$$

Thay vì dự đoán trực tiếp z , mô hình ánh xạ z về khoảng $[0, 1]$ bằng hàm sigmoid:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Trong đó:

- $x_1, \dots, x_n$: các đặc trưng đầu vào
- $w_0, \dots, w_n$: các trọng số mô hình
- $\hat{y}$: xác suất mẫu thuộc lớp 1
- $\sigma(z)$: hàm sigmoid, giúp biến một giá trị thực bất kỳ thành xác suất

II.2 Hàm sigmoid

Hàm sigmoid là trung tâm của Logistic Regression. Nó có dạng:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Đặc tính:

- Đầu ra luôn trong khoảng $(0, 1)$.
- Khi z lớn, $\sigma(z) \approx 1$.
- Khi z nhỏ, $\sigma(z) \approx 0$.
- Đường cong hình chữ “S” (S-shaped curve).

Sigmoid giải quyết vấn đề: *“Làm thế nào biến một kết hợp tuyến tính bất kỳ thành xác suất hợp lệ?”*

II.3 Hàm logit và odds

Để giải thích Logistic Regression dưới dạng tuyến tính, ta dùng hàm logit:

$$\text{logit}(\hat{y}) = \ln \left(\frac{\hat{y}}{1 - \hat{y}} \right)$$

Vì $\hat{y} = \sigma(z)$, nên:

$$\text{logit}(\hat{y}) = z = w_0 + w_1x_1 + \dots + w_nx_n$$

Giải thích:

- $\frac{\hat{y}}{1 - \hat{y}}$ là **odds**: tỷ lệ “có xảy ra” trên “không xảy ra”.
- Logit biến odds thành dạng tuyến tính, từ đó cho phép mô hình tối ưu giống như Linear Regression.

II.4 Hàm mất mát (Loss function)

Do đầu ra là xác suất, ta không thể dùng MSE như linear regression. Thay vào đó mô hình tối ưu hóa **Binary Cross-Entropy**:

$$L(\mathbf{w}) = - \sum_{i=1}^m [y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)]$$

Trong đó:

- m : số mẫu
- y_i : nhãn thực tế (0 hoặc 1)
- $\hat{y}_i = \sigma(w_0 + w_1 x_{i1} + \dots + w_n x_{in})$

Loss này trừng phạt mạnh khi mô hình dự đoán xác suất sai lệch lớn so với nhãn thực.

II.5 Ví dụ minh họa Logistic Regression với dataset nhỏ

Giả sử ta có dataset gồm 2 biến đầu vào x_1, x_2 và nhãn $y \in \{0, 1\}$:

Mẫu	x_1	x_2	y (thực tế)
1	1	2	0
2	2	1	0
3	3	4	1
4	4	3	1

Dataset minh họa

Giả sử mô hình học được trọng số:

$$w_0 = -3, \quad w_1 = 0.8, \quad w_2 = 1$$

Bước 1: Tính giá trị tuyến tính

$$z_i = w_0 + w_1 x_{i1} + w_2 x_{i2}$$

Mẫu	z
1	-0.2
2	-0.4
3	3.4
4	3.2

Tính z

Bước 2: Tính xác suất bằng sigmoid

$$\hat{y}_i = \sigma(z_i)$$


Mẫu	z	$\hat{y}$
1	-0.2	0.4502
2	-0.4	0.4013
3	3.4	0.9677
4	3.2	0.9608

Xác suất dự đoán

Bước 3: Dự đoán lớp (threshold = 0.5)

Mẫu	$\hat{y}$	Dự đoán
1	0.4502	0
2	0.4013	0
3	0.9677	1
4	0.9608	1

Dự đoán lớp



Đồ thị minh họa hàm Sigmoid

III Nhận xét

III.1 Ưu điểm

- Mô hình đơn giản, dễ triển khai.
- Giải thích được ý nghĩa các trọng số.
- Dự đoán xác suất – hữu ích trong nhiều bài toán.
- Hiệu quả khi dữ liệu tách tuyến tính.

III.2 Nhược điểm

- Chỉ mô hình hóa ranh giới tuyến tính.
- Nhạy cảm với outliers.
- Không bắt được quan hệ phi tuyến trừ khi dùng thêm feature engineering.
- Hoạt động kém với dữ liệu mất cân bằng.