

Random Forest

I. Giới thiệu về Random Forest

Random Forest là một thuật toán **ensemble** dựa trên nhiều cây quyết định (Decision Trees). Ý tưởng chính là kết hợp nhiều cây riêng lẻ để đưa ra dự đoán tổng hợp, giúp giảm overfitting và cải thiện độ chính xác so với một cây duy nhất.

Thuật toán hoạt động bằng cách:

- Tạo nhiều cây quyết định từ các mẫu ngẫu nhiên của dữ liệu huấn luyện (**bootstrap sampling**).
- Tại mỗi nút, chỉ chọn một tập con các feature ngẫu nhiên để quyết định cách chia tách.
- Kết hợp dự đoán của tất cả các cây:
 - **Classification**: lấy lớp được dự đoán nhiều nhất (bỏ phiếu đa số).
 - **Regression**: lấy trung bình kết quả từ tất cả cây.

II. Toán học đằng sau Random Forest

Random Forest kết hợp nhiều cây quyết định bằng cách sử dụng **bagging** và **feature randomness**. Quy trình toán học cơ bản gồm các bước sau:

1. Bootstrap Sampling (Bagging)

Tạo B mẫu ngẫu nhiên từ dữ liệu gốc, mỗi mẫu cùng kích thước như dữ liệu gốc nhưng **có lặp lại**. Mỗi mẫu này dùng để huấn luyện một cây quyết định riêng biệt. Giúp tăng tính đa dạng giữa các cây, giảm overfitting.

2. Feature Randomness

Khi xây dựng mỗi cây, tại mỗi nút:

- Chọn ngẫu nhiên một tập con các feature (thay vì xét toàn bộ feature).
- Chọn split tốt nhất dựa trên chỉ số **impurity** (Gini, Entropy cho classification hoặc MSE, MAE cho regression).

Điều này làm giảm tương quan giữa các cây, tăng độ ổn định của dự đoán tổng hợp.

3. Aggregation (Ensemble)

Sau khi tất cả cây được huấn luyện:

Classification:

$$\hat{C} = \text{majority_vote}\{h_1(X), h_2(X), \dots, h_B(X)\}$$

với $h_i(X)$ là dự đoán của cây thứ i , lớp có nhiều phiếu nhất được chọn.

Regression:

$$\hat{y} = \frac{1}{B} \sum_{i=1}^B h_i(X)$$

trung bình kết quả dự đoán từ tất cả cây.

Sự cải thiện so với Decision Tree

Bagging + feature randomness giúp mỗi cây **khác biệt**, tránh overfitting như một cây đơn.

Kết hợp dự đoán từ nhiều cây làm **giảm sai số**, tăng độ chính xác tổng thể.

Thuật toán vẫn dựa trên nguyên lý chia tách dữ liệu theo **impurity** như Decision Tree, nhưng kết quả dự đoán là tổng hợp của nhiều cây.

III. Ưu nhược điểm của Random Forest

Ưu điểm

- Giảm overfitting so với một cây quyết định đơn lẻ.
- Hoạt động tốt với cả dữ liệu số và dữ liệu danh mục.
- Có thể mở rộng cho tập dữ liệu lớn.
- Có thể đánh giá mức độ quan trọng của từng feature (**feature importance**).
- Dự đoán ổn định hơn, nhờ kết hợp nhiều cây khác nhau.

Nhược điểm

- Mất tính trực quan: khó giải thích quyết định từng mẫu như một cây đơn lẻ.
- Tốn bộ nhớ và thời gian tính toán hơn Decision Tree.

- Khi dữ liệu cực lớn, cần tối ưu hóa hoặc sử dụng sampling để giảm thời gian huấn luyện.
- Không phù hợp nếu cần một mô hình cực kỳ nhanh, đơn giản, nhỏ gọn.