

Support Vector Machine (SVM)

I Giới thiệu


Trong lĩnh vực Machine Learning, một trong những bài toán cơ bản là **phân loại (classification)**: dự đoán nhãn của dữ liệu dựa trên các đặc trưng đầu vào. Ví dụ:

- Nhận diện email *spam* hay không spam.
- Phân loại hình ảnh mèo – chó.
- Xác định khách hàng tiềm năng.

Support Vector Machine (SVM) là một thuật toán phân loại tuyến tính mạnh mẽ, phát triển bởi Vladimir Vapnik và cộng sự, nổi bật nhờ:

1. **Tối đa hóa margin**: SVM chọn hyperplane sao cho khoảng cách nhỏ nhất từ dữ liệu đến hyperplane (margin) là lớn nhất, tăng khả năng tổng quát hóa, giảm overfitting.
2. **Xác định điểm quyết định (support vectors)**: Chỉ những điểm nằm gần biên quyết định vị trí hyperplane. Các điểm còn lại có $\lambda_i = 0 \rightarrow$ không tác động đến hyperplane.
3. **Tối ưu hóa lỗi với ràng buộc rõ ràng**: Chuyển bài toán sang *dual* để tận dụng tính chất lồi, dễ giải bằng quadratic programming, đồng thời mở ra khả năng kernel.
4. **Mở rộng cho dữ liệu không tuyến tính và nhiễu**: Sử dụng *soft-margin* cho phép một số điểm vi phạm margin nhưng vẫn tối ưu tổng thể.

Trực quan: Hãy tưởng tượng bạn vẽ một đường phân tách hai nhóm điểm trên giấy. SVM chọn đường sao cho khoảng cách từ đường tới điểm gần nhất của mỗi nhóm là lớn nhất. Các điểm gần đường thẳng này là support vectors, quyết định hyperplane.



Mô hình SVM

II Bài toán SVM

1. Bài toán phân tách tuyến tính

Giả sử có tập dữ liệu hai lớp:

$$(x_i, y_i), \quad y_i \in \{-1, +1\}$$

Mô hình tuyến tính phân tách hai lớp:

$$w^T x + b = 0$$

$$w^T x + b > 0 \Rightarrow \text{dự đoán lớp } +1$$

$$w^T x + b < 0 \Rightarrow \text{dự đoán lớp } -1$$

Câu hỏi: Trong vô số hyperplane phân tách được hai lớp, làm sao chọn hyperplane “tốt nhất”?

2. Khoảng cách từ điểm đến hyperplane

Khoảng cách Euclid từ điểm x đến hyperplane $w^T x + b = 0$:

$$d(x) = \frac{|w^T x + b|}{\|w\|}$$

Với nhãn y_i , khoảng cách có dấu:

$$\frac{y_i(w^T x_i + b)}{\|w\|}$$

- Điểm nằm đúng phía $\rightarrow$ dương
- Điểm nằm sai phía $\rightarrow$ âm
- Điểm nằm sát hyperplane $\rightarrow$ bằng 0

Phân tách hoàn hảo cần:

$$y_i(w^T x_i + b) > 0$$

3. Margin và chuẩn hóa

Margin (γ) là khoảng cách nhỏ nhất từ dữ liệu đến hyperplane:

$$\gamma = \min_i \frac{y_i(w^T x_i + b)}{\|w\|}$$

Chuẩn hóa: Vì nếu nhân (w, b) với $k > 0$, hyperplane không thay đổi nhưng margin có thể phóng lớn hoặc thu nhỏ, ta chuẩn hóa:

$$\min_i y_i(w^T x_i + b) = 1 \quad \Rightarrow \quad y_i(w^T x_i + b) \geq 1$$

Sau chuẩn hóa:

$$\gamma = \frac{1}{\|w\|}$$

Tối đa hóa margin $\Leftrightarrow$ tối thiểu $\|w\|$, viết thuận tiện:

$$\min \frac{1}{2} \|w\|^2$$

4. Bài toán Primal (tối ưu lồi)

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, N \end{aligned}$$

- Hàm mục tiêu: convex (hàm lồi)
- Ràng buộc: tuyến tính

5. Lagrangian SVM

Để giải bài toán có ràng buộc:

$$\mathcal{L}(w, b, \lambda) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \lambda_i (1 - y_i (w^T x_i + b)), \quad \lambda_i \geq 0$$

- λ_i : Lagrange multiplier, phạt điểm vi phạm ràng buộc
Tiến trình:

1. Lấy đạo hàm theo $w, b \rightarrow$ cực trị
2. Thay ngược lại $\rightarrow$ bài toán dual

6. Điều kiện cực trị

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \Rightarrow w = \sum_i \lambda_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_i \lambda_i y_i = 0$$

7. Bài toán Dual SVM

$$\begin{aligned} \max_{\lambda_i \geq 0} \quad & \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j=1}^N \lambda_i \lambda_j y_i y_j (x_i^T x_j) \\ \text{s.t.} \quad & \sum_i \lambda_i y_i = 0 \end{aligned}$$

Ưu điểm:

- Chỉ cần tích vô hướng $x_i^T x_j \rightarrow$ hỗ trợ kernel
- Bài toán nhỏ nếu số support vector nhỏ
- Xác định điểm ảnh hưởng trực tiếp đến hyperplane

8. Điều kiện KKT

Tập hợp đầy đủ các điều kiện tối ưu (KKT) phải được thỏa mãn tại nghiệm tối ưu (w^*, b^*, λ^*) :

1. $\frac{\partial \mathcal{L}}{\partial w} = 0$ và $\frac{\partial \mathcal{L}}{\partial b} = 0$ (Đã được sử dụng để suy ra bài toán Dual)

2. $\lambda_i \geq 0$ (Khả thi Kép)
 3. $\mathbf{y}_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ (Khả thi Nguyên thủy)
 4. $\lambda_i(1 - y_i(w^T x_i + b)) = 0$
- $\lambda_i > 0 \rightarrow$ điểm nằm trên margin
 - $\lambda_i = 0 \rightarrow$ điểm xa margin, không ảnh hưởng hyperplane

9. Support Vectors

Tập các chỉ số $\lambda_i > 0$ gọi là support vectors. Hyperplane chỉ phụ thuộc support vectors:

$$w = \sum_{i \in SV} \lambda_i y_i x_i$$

Bias b tính từ một support vector k bất kỳ:

$$b = y_k - w^T x_k$$

10. Soft-Margin SVM

Khi dữ liệu không tuyến tính phân tách hoàn hảo, giới thiệu slack variable $\xi_i \geq 0$:

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

Hàm mục tiêu:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

- C điều chỉnh trade-off margin vs lỗi - C lớn $\rightarrow$ ít lỗi, margin hẹp, dễ overfit - C nhỏ $\rightarrow$ chấp nhận nhiều lỗi, margin rộng, tổng quát tốt

11. Kernel SVM


Với dual, bài toán chỉ xuất hiện tích vô hướng $x_i^T x_j$. Khi dữ liệu phi tuyến, ánh xạ lên không gian cao chiều:

$$\phi : x \mapsto \phi(x), \quad K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$


Một số kernel phổ biến:

- Linear: $K(x, z) = x^T z$
- Polynomial: $K(x, z) = (\gamma x^T z + r)^d$

- RBF/Gaussian: $K(x, z) = \exp(-\gamma \|x - z\|^2)$
- Sigmoid: $K(x, z) = \tanh(\gamma x^T z + r)$



Dữ liệu trước khi qua Kernel



Dữ liệu sau khi ánh xạ qua Kernel

12. Hàm phân loại cuối cùng

$$f(x) = \sum_{i \in SV} \lambda_i y_i K(x_i, x) + b$$

- Dự đoán: $f(x) > 0 \Rightarrow +1$, $f(x) < 0 \Rightarrow -1$ - Chỉ support vectors quyết định boundary, các điểm khác không ảnh hưởng.

III Ví dụ SVM

Dữ Liệu Bài Toán

Sử dụng bộ 4 điểm đã chọn:

Điểm	x_1	x_2	y
1	1	2	1
2	2	3	1
3	0	0	-1
4	2	0	-1

Ma trận tích vô hướng:

$$\begin{aligned} x_1^T x_1 &= 1, & x_1^T x_2 &= 2, & x_1^T x_3 &= 0, & x_1^T x_4 &= -1 \\ x_2^T x_2 &= 5, & x_2^T x_3 &= 0, & x_2^T x_4 &= -1 \\ x_3^T x_3 &= 0, & x_3^T x_4 &= 0 \\ x_4^T x_4 &= 2 \end{aligned}$$

Ma trận Q :

$$Q = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 2 & 5 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 2 \end{bmatrix}$$

Bài toán Dual (tổng quát):

$$\begin{aligned} \max_{\lambda_i \geq 0} \quad & \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j=1}^N \lambda_i \lambda_j y_i y_j (x_i^T x_j) \\ \text{s.t.} \quad & \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0 \quad (\text{Ràng buộc Đẳng thức } R) \\ & \lambda_i \geq 0, \quad i = 1, \dots, 4 \quad (\text{Ràng buộc Bất đẳng thức } I) \end{aligned}$$

a. Phân Tích Bằng KKT và Ràng Buộc Bất Đẳng Thức

Ta khử biến λ_4 từ ràng buộc (R): $\lambda_4 = \lambda_1 + \lambda_2 - \lambda_3$. Hàm mục tiêu L_D chỉ theo $\lambda_1, \lambda_2, \lambda_3$ (sau khi thay thế):

$$L_D = 2(\lambda_1 + \lambda_2) - \frac{1}{2}(\lambda_1^2 + \lambda_2^2 + 2\lambda_3^2 + 4\lambda_1\lambda_3 + 8\lambda_2\lambda_3)$$

b. Tìm Cực Trị Tự Do (Nơi Đạo Hàm Bằng 0)

Đặt đạo hàm bậc nhất bằng 0:

$$\begin{cases} \frac{\partial L_D}{\partial \lambda_1} = 2 - \lambda_1 - 2\lambda_3 = 0 \implies \lambda_1 = 2 - 2\lambda_3 & (E1) \\ \frac{\partial L_D}{\partial \lambda_2} = 2 - \lambda_2 - 4\lambda_3 = 0 \implies \lambda_2 = 2 - 4\lambda_3 & (E2) \\ \frac{\partial L_D}{\partial \lambda_3} = -2\lambda_3 - 2\lambda_1 - 4\lambda_2 = 0 \implies \lambda_1 + 2\lambda_2 + \lambda_3 = 0 & (E3) \end{cases}$$

Thay (E1) và (E2) vào (E3):

$$(2 - 2\lambda_3) + 2(2 - 4\lambda_3) + \lambda_3 = 0 \implies 6 - 9\lambda_3 = 0$$

$$\lambda_3 = \frac{2}{3}$$

Thay λ_3 ngược lại:

$$\lambda_1 = 2 - 2\left(\frac{2}{3}\right) = \frac{2}{3}$$

$$\lambda_2 = 2 - 4\left(\frac{2}{3}\right) = -\frac{2}{3}$$

c. Kết Luận về Ràng Buộc (I)

Kết quả $\lambda_2 = -2/3$ vi phạm ràng buộc bất đẳng thức $\lambda_2 \geq 0$. Do đó, nghiệm tối ưu không nằm ở cực trị tự do mà phải nằm trên biên $\lambda_2 = 0$.

d. Giải Bài Toán Trên Biên $\lambda_2 = 0$

Đặt $\lambda_2 = 0$ và giải hệ KKT lại (chỉ với λ_1, λ_3):

1. Từ (E2), đặt $\lambda_2 = 0$: $2 - 0 - 4\lambda_3 = 0 \implies \lambda_3 = \frac{1}{2}$

2. Từ (E3), đặt $\lambda_2 = 0$: $\lambda_1 + 0 + \lambda_3 = 0 \implies \lambda_1 = -\lambda_3$

Thay $\lambda_3 = 1/2$ vào $\lambda_1 = -\lambda_3$:

$$\lambda_1 = -\frac{1}{2}$$

e. Kết Luận về Ràng Buộc (II)

Kết quả $\lambda_1 = -1/2$ vi phạm ràng buộc bất đẳng thức $\lambda_1 \geq 0$. Do đó, nghiệm tối ưu phải nằm trên giao của các biên $\lambda_1 = 0$ và $\lambda_2 = 0$.

f. Nghiệm Hợp Lệ Duy Nhất (Trên Biên $\lambda_1 = 0, \lambda_2 = 0$)

Nếu $\lambda_1 = 0$ và $\lambda_2 = 0$:

1. Từ (R): $\lambda_4 = \lambda_1 + \lambda_2 - \lambda_3 \implies \lambda_4 = -\lambda_3$

2. Vì $\lambda_3 \geq 0$ và $\lambda_4 \geq 0$, điều này chỉ xảy ra khi $\lambda_3 = 0$ và $\lambda_4 = 0$.

Tuy nhiên, nghiệm $\lambda_i = 0$ không phải là nghiệm SVM (vì $w = 0$). Ta phải sử dụng điều kiện $\lambda_1 - \lambda_4 = 0$ và w phải được xác định bởi ít nhất 2 SV. Do đó, ta quay lại giải hệ tuyến tính của các SV thực tế (chỉ λ_1, λ_4):

Đặt $\lambda_2 = 0, \lambda_3 = 0$ và $\lambda_1 = \lambda_4 = \lambda$. Ta giải hệ KKT cho $k = 1$ và $k = 4$:

$$\begin{cases} 3\lambda + \alpha = 1 & (T1) \\ 2\lambda - \alpha = 1 & (T2) \end{cases}$$

Cộng (T1) và (T2): $5\lambda = 2 \implies \lambda = \frac{2}{5}$

Nguồn gốc hệ tuyến tính Dual

Mặc dù 4 điều kiện trên là của bài toán Primal, hệ phương trình để giải λ trong bài toán Dual ($3\lambda + \alpha = 1$ và $2\lambda - \alpha = 1$) được suy ra từ việc áp dụng **Điều kiện Cực trị** vào bài toán Dual mở rộng (bao gồm nhân tử Lagrange α cho ràng buộc $\sum \lambda_i y_i = 0$).

Công thức tổng quát dẫn đến hệ tuyến tính là:

$$1 - \sum_{j=1}^N \lambda_j \mathbf{Q}_{kj} - \alpha \mathbf{y}_k = 0 \quad (\text{Áp dụng cho mọi Support Vector } k)$$

Điều kiện này chính là đạo hàm của hàm Dual $\mathcal{L}_D(\lambda)$ theo λ_k (kết hợp với nhân tử α).

g. Kết Quả λ (Nghiệm tối ưu)

$$\lambda_1 = \frac{2}{5}, \quad \lambda_2 = 0, \quad \lambda_3 = 0, \quad \lambda_4 = \frac{2}{5}$$

h. Tính Toán Tham Số Cuối Cùng

Vector Trọng số w

$$\begin{aligned} w &= \lambda_1 y_1 x_1 + \lambda_4 y_4 x_4 \\ &= \frac{2}{5}(1)[1, 2] + \frac{2}{5}(-1)[2, 0] = \frac{2}{5}[-1, 2] = \left[-\frac{2}{5}, \frac{4}{5}\right] \end{aligned}$$

Bias b


Sử dụng $x_1 = [1, 2], y_1 = 1$:

$$b = y_1 - w^T x_1 = 1 - \left(-\frac{2}{5}(1) + \frac{4}{5}(2)\right) = 1 - \frac{6}{5} = -\frac{1}{5}$$

i. Hyperplane Phân Loại

$$\begin{aligned} w^T x + b &= 0 \implies -\frac{2}{5}x_1 + \frac{4}{5}x_2 - \frac{1}{5} = 0 \\ -2x_1 + 4x_2 - 1 &= 0 \end{aligned}$$

Trực quan hóa SVM Chính xác bằng Nghiệm Toán học



IV Ưu điểm và Nhược điểm của SVM

Ưu điểm

- **Hiệu quả cao ở không gian chiều lớn:** SVM hoạt động rất tốt khi số chiều (feature) lớn hơn nhiều so với số mẫu.
- **Tối ưu hoá biên (margin):** Mục tiêu của SVM là tìm siêu phẳng có biên lớn nhất, giúp mô hình có khả năng tổng quát hóa tốt.
- **Linh hoạt nhờ Kernel Trick:** SVM có thể học được cả các quan hệ phi tuyến thông qua các kernel như RBF, Polynomial, Sigmoid mà không cần biến đổi thủ công dữ liệu.
- **Ít bị overfitting:** Việc tối đa hoá margin kết hợp với regularization giúp mô hình ít bị quá khớp so với nhiều thuật toán khác.
- **Hữu ích trong các bài toán biên rõ ràng:** Khi ranh giới giữa các lớp sắc nét, SVM thường đạt kết quả rất tốt.

Nhược điểm

- **Chi phí tính toán lớn với dữ liệu lớn:** Việc giải bài toán tối ưu bậc hai (quadratic programming) rất tốn thời gian khi số mẫu lớn ($N > 10^4$).
- **Khó lựa chọn kernel phù hợp:** Hiệu năng phụ thuộc mạnh vào việc chọn kernel và tham số (C , γ). Nếu chọn sai, mô hình hoạt động kém.
- **Không phù hợp cho dữ liệu nhiễu cao:** Khi dữ liệu có nhiều outliers hoặc biên giữa các lớp không rõ ràng, SVM dễ bị giảm độ chính xác.
- **Không cho ra xác suất trực tiếp:** SVM chỉ cho nhãn phân loại, muốn có xác suất phải dùng thêm các phương pháp như Platt Scaling.
- **Tốn bộ nhớ với kernel phi tuyến:** Khi dùng kernel, SVM phải lưu ma trận Gram kích thước $N \times N$, rất nặng với tập dữ liệu lớn.